ИТОГОВЫЙ ОТЧЁТ / 31 ОКТЯБРЯ 2026

Автоматизация генерации признаков в рекомендательных системах

Проверка экспериментов на Yambda-50M, уточнение результатов Optuna и воспроизводимости.

Главный результат

Автоматический набор признаков показал более высокий точечный NDCG@10 в повторном прогоне с сохранёнными параметрами Optuna: **0,0978 против 0,0951**. Статистически подтверждённое превосходство не показано.

Разность NDCG@10: **+0,002700**; 95% парный bootstrap-интервал: **[-0,004240; +0,009805]**. Интервал включает ноль. Отсутствие значимой разницы не доказывает эквивалентность или «не хуже».

Что проверено

Прочитаны README, ноутбук, CSV, JSON и исходный PDF. Дополнительно изучен локальный src и проверены шесть parquet-таблиц. Выполнено повторное обучение четырёх классификаторов и 2000 повторов bootstrap по пользователям.

Что ограничивает вывод

Повторный прогон использует прежние таблицы. Обнаружен отсутствующий часовой зазор на горизонт метки у границ выборок. Исправление подготовлено для пересборки; старые метрики не являются проверкой исправленного временного протокола.

Исторические артефакты сохранены отдельно. Новый полный поиск Optuna не выполнялся; повторно применены сохранённые best_params. Исходный бюджет и история поиска не сохранились.

1. Постановка и признаки

Проект проверяет, может ли шаблонная генерация признаков заменить ручной выбор временных окон для рекомендательной модели LightGBM.

Данные и метка

Выбраны 5000 пользователей Yambda-50M со всей историей, seed=42. Строка представляет прослушивание. label=1, если первый лайк пары пользователь/трек произошёл в течение часа после прослушивания. Уже лайкнутые до cutoff пары исключены.

Кандидаты - реально наблюдённые прослушивания за будущий период, включая повторы одной пары. Это оценка порядка событий, а не рекомендаций уникальных треков всего каталога. Доступность is_organic в реальном будущем сценарии отдельно не подтверждена.

Часть	Строк	Пользователей	С позитивом
train	2 349 940	4424	2047
val	1 309 444	4371	1623
test	1 333 420	4941	1656

NDCG@10 и Recall@10 усредняются только по пользователям с положительной меткой. Поэтому на test участвуют 1656 пользователей, а не вся исходная подвыборка. AUC считается по строкам.

Разделение по времени

Обучение собрано из четырёх недельных срезов перед val. Val и test занимают следующие 14-дневные интервалы. Для каждого среза история признаков ограничена событиями строго до cutoff.

Ручной и автоматический наборы

Ручные признаки: 37 для пользователя, трека и пары; 61 с добавлением user×artist и user×album. Окна: 1, 7, 30 дней и all-time. Автоматический генератор создаёт 151 используемый признак: пять сущностей, счётчики/конверсии и окна 1, 3, 7, 14, 21, 30, 60, 90, 180 дней и all-time; средняя доля прослушивания для пользователя и трека.

Важность длинных окон интересна, но не доказывает причинное преимущество. Ручной набор уже содержит всю историю. В архиве сохранены отбор top-37, корреляционный отсев и LambdaRank; заново они не обучались.

2. Результаты и Optuna

Повторный прогон на существующих кешах

Модель	NDCG val	NDCG test	Recall test
default manual, 61	0,083245	0,097539	0,124424
Optuna params manual, 61	0,094114	0,095070	0,125752
default auto, 151	0,085212	0,091007	0,119185
Optuna params auto, 151	0,089725	0,097770	0,123910

Среди ручных вариантов по val выбрана модель с сохранёнными параметрами Optuna. Сравнение настроенных моделей на test даёт +0,002700 (около +2,84%) в пользу автонабора. Среднее bootstrap +0,002617; 95% CI [-0,004240; +0,009805]. Параметры не выбирались по этому test.

Исторические результаты

Модель	NDCG val	NDCG test	Recall test
default manual	0,0777	0,0852	0,1136
Optuna manual	0,0837	0,0883	0,1181
default auto	0,0812	0,0848	0,1151
Optuna auto	0,0820	0,0909	0,1186

Историческая точечная разность +0,0026 отличается от bootstrap mean +0,001726 в JSON; CI [-0,002900; +0,007123]. Это разные статистики. Причину расхождения без исходных предсказаний установить нельзя. Повторный прогон не воспроизводит прежние числа: изменены seed обучения и правило ничьих; исходные версии среды не зафиксированы.

Новый протокол поиска

Добавлен src/tuning.py: по 30 trials на набор, одинаковое пространство параметров, TPE seed=42, последовательный поиск, максимизация NDCG@10 на val. Early stopping - binary logloss на val. Test в функцию поиска не передаётся. История сохраняется в SQLite и CSV. Проверен один синтетический trial; полный поиск не запускался.

Исторический JSON не содержит trials, seed, пространства поиска и best_iteration. Поэтому равенство исходных бюджетов не доказано, а утверждение старого PDF «Optuna не запускался» заменено на более точное описание.

3. Корректность экспериментов

Временные границы меток

Исходный код не оставляет часовой зазор на горизонт метки. Последние события train могут получить метку из val, последние события val - из test. В конце наблюдений возможны незавершённые метки. Сохранённые таблицы не содержат timestamp и cutoff, поэтому проверить это по кешам нельзя.

Исправленные build_train/build_train_auto исключают последний час каждого недельного окна. prepare_data.py также исключает последний час val и test и пишет новые таблицы в data/rebuilt/. Полноту исходных likes до конца listens нужно подтвердить при пересборке. Этот этап пока не выполнен.

Ноутбук и источники чисел

Исходный ноутбук смешивал расчёты для 2000 и 5000 пользователей, переопределял импортированные функции и зависел от состояния ядра. Часть CSV/JSON была вписана вручную. Новый ноутбук линейно загружает таблицы, проверяет соответствие, обучает четыре модели и сохраняет метрики из предсказаний. Исходная история оставлена в архиве.

Парный bootstrap

Раньше при пересэмплировании заново добавлялся случайный jitter к score. Теперь NDCG считается один раз по каждому пользователю; затем пересэмплируются парные пользовательские разности. Неравные score не меняются; точные ничьи разрешаются порядком строк. Point delta, bootstrap mean и границы интервала хранятся отдельно.

Прочие ограничения

Один seed пользователей и многократно просмотренный test не дают независимой подтверждающей оценки. Отсутствие значимости не доказывает non-inferiority. В исходных train-таблицах ранкера не сохранён явный snapshot_id: при новом ranker-прогоне нужен ключ (cutoff, uid).

В bootstrap относительно manual+artist/album архивный auto-pruned имеет CI ниже нуля. Поэтому старое утверждение «все интервалы классификаторов включают ноль» неверно. Преимущество ранкера над слабой ручной базой не доказывает победу над лучшей ручной моделью.

4. Проверки и итоговая поставка

Выполненная валидация

Проверены совпадение uid/item_id/label и порядка строк ручных и авто-таблиц во всех сплитах, нулевые ui_likes_all после фильтра, размеры и позитивная популяция. Сохранены SHA-256 исходных parquet, параметры и версии проверочного запуска.

Автотесты проверяют известные ранжирования, точные ничьи, ошибочные score и отсутствие позитивов; постоянную разность bootstrap; совпадение общих ручных/авто-признаков; исключение события на cutoff; часовой зазор. Smoke-test Optuna подтвердил создание study, выполнение trial и сохранение CSV.

Четыре классификатора обучены на существующих кешах. В поставке есть выполненный ноутбук, CSV, JSON bootstrap на 2000 повторов, важности и файлы моделей. Окружение: Python 3.14.0, LightGBM 4.7.0; прочие версии в requirements-checked.txt и run_metadata.json.

Как использовать

1. Распаковать итоговый архив; команды переноса в существующий репозиторий находятся в GITHUB.md.
2. Установить requirements.txt и выполнить python -m unittest discover -s tests.
3. Для проверки прежних кешей указать RECSYS_DATA_DIR и запустить T-Lab.ipynb последовательно.
4. Для исправленного протокола сначала запустить prepare_data.py, затем использовать data/rebuilt/ и повторить обучение.
5. Для нового полного поиска включить RUN_SEARCH=True и выбрать уникальный STUDY_TAG.

Готовность и оставшаяся работа

Проект подготовлен к публикации как исследовательская работа с явно указанными ограничениями. Команды Git создают отдельную ветку и позволяют проверить изменения перед commit/push. Исходный репозиторий не изменён, публикация не выполнялась.

Не выполнены полный rebuild из сырых событий, новый поиск Optuna на 30+30 trials, новые ranker/top-37 эксперименты, несколько seed и оценка на новом закрытом test. До пересборки нельзя заявлять, что выявленная проблема временных границ устранена в опубликованных метриках.

Источники: предоставленные README, T-Lab.ipynb, results_final.csv, results_auto.csv, optuna_results.json, bootstrap JSON, full_explanation.pdf и локальный src/data. Документация Optuna: optuna.readthedocs.io/en/stable/faq.html и tutorial/20_recipes/001_rdb.html.